Python

Pandas/상관관계

김선녕(sykim.lecture@gmail.com)

참고문헌: 파이썬을 이용한 빅데이터 수집, 분석과 시각화 - 비팬북스, 이원화

Pandas Library

상관관계

- Powerful Python data analysis toolkit
- BSD-licensed library providing high-performance, easy-to-use data structures and data analysis tools for the Python programming language.
- The two primary data structures of pandas, Series (1-dimensional) and DataFrame (2-dimensional), handle the vast majority of typical use cases in finance, statistics, social science, and many areas of engineering.
- pip install pandas
- Ref: https://pandas.pydata.org

- 인덱스(레이블)를 가지는 동일한 데이터형의 1차원 데이터
- 인덱스는 중복 가능
- 레이블 또는 데이터의 위치를 지정한 추출가능.
- 인덱스에 대한 슬라이스가 가능
- 산술 연산이 가능. 통계량을 산출하는 장점을 가지고 있음

Indet	Oata
1	'A'
2	'B'
3	'C'
4	'D'
5	'E'


```
import numpy as np
import pandas as pd
s = pd.Series(np.random.randn(5))
S
   -0.086872
  0.260547
  0.012375
3 -1.185436
4 -0.985884
dtype: float64
s = pd.Series(np.random.randn(5), index=['A','B','C','D','E'])
S
   1.172776
   0.295672
В
  -1.450593
D
  0.394875
   1.411907
dtype: float64
```

```
# dictionary
d = \{ 'a' : 0., 'b' : 1., 'c' : 2. \}
pd.Series(d)
    0.0
а
  1.0
b
  2.0
dtype: float64
pd.Series(d, index=['a', 'b', 'B', 'c'])
    0.0
а
  1.0
b
    NaN
    2.0
dtype: float64
# 스칼라값
pd.Series(7, index=['a', 'b', 'c', 'd', 'e'])
а
b
dtype: int64
```

Series

```
s = pd.Series([1,2,3,4,5], index=['a', 'b', 'c', 'd', 'e'])
s[0]
s[:3]
b 2
dtype: int64
s[[4,1]]
e 5
dtype: int64
np.power(s, 2)
а
b
    16
    25
dtype: int64
```

- 행과 열에 레이블을 가진 2차원 데이터
- 열마다 다른 형태를 가질 수 있음
- 테이블형 데이터에 대해 불러오기, 데이터 쓰기가 가능
- DataFrame끼리 여러 가지 조건을 사용한 결합 처리가 가능
- 크로스 집계가 가능



	Regd. No	Name	Marks%
Ī	1000	Steve	86.29
	1001	Mathew	91.63
-	1002	Jose	72.90
	1003	Patty	69.23
	1004	Vin	88.30

DataFrame

pd.DataFrame(d)

	one	two
а	1.0	1.0
b	2.0	2.0
С	3.0	3.0
d	NaN	4.0

```
# 인텍스 값을 부여하지 않으면 자동으로 0부터 두개의 데이터 중 큰 배열의 길이 - 1 만큼이 부여
d = {'one' : pd.Series([1., 2., 3.]), 'two' : pd.Series([1., 2., 3., 4.])}
pd.DataFrame(d)
```

```
one two1.01.02.03.03.04.0
```

```
d = {'one' : [1., 2., 3., 4.], 'two' : [4., 3., 2., 1.]}
pd.DataFrame(d)
```

```
one two
1.0 4.0
2.0 3.0
3.0 2.0
4.0 1.0
```

```
# Dict 리스트 데이터의 활용
data2 = [{'a': 1, 'b': 2}, {'a': 5, 'b': 10, 'c': 20}]
pd.DataFrame(data2)
```

```
a b c0 1 2 NaN1 5 10 20.0
```

```
pd.DataFrame(data2, index=['first', 'second'])
```

```
        a
        b
        c

        first
        1
        2
        NaN

        second
        5
        10
        20.0
```

```
pd.DataFrame(data2, columns=['a', 'b'])
```

```
0 1 2
1 5 10
```

```
df = pd.DataFrame(data2, columns=['a', 'b'])
df.rename(columns={'a':'COL1'})
```

	b	
0	1	2
1	5	10

```
df.set_index('b')
```

a

b 2 1

10 5

```
# 데이터 추가 및 합치기(merge)
data1 = [{'name':'Mark'},{'name':'Eric'},{'name':'Jennifer'}]
df = pd.DataFrame(data1)
df
```

name

- 0 Mark
- 1 Eric
- 2 Jennifer

```
df['age'] = [10, 11, 12]
pd.DataFrame(data1)
df
```

	name	age
0	Mark	10
1	Eric	11
2	Jennifer	12

```
data2 = [{'sido':'서울'}, {'sido':'경기'}, {'sido':'인천'}]
df2 = pd.DataFrame(data2)
df2
```

sido


- 0 서울
- 1 경기
- 2 인천

pd.merge(df, df2, left_index=True, right_index=True)

	name	age	sido
0	Mark	10	서울
1	Eric	11	경기
2	Jennifer	12	인천

데이터 시각화

```
# Series에서 시작화
s = pd.Series([1,2,3])
ax = s.plot()
ax.set_title('Line Chart')
plt.show()
```



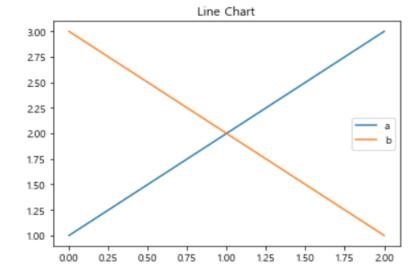
```
# DataFrameOff A A 목률

df = pd.DataFrame({'a':[1,2,3], 'b':[3,2,1]})

ax = df.plot()

ax.set_title('Line Chart')


plt.show()
```



난수(random) 데이터를 얻는 함수

함수	설명	
rand(d0, d1,, dn)	N차원 배열의 난수 발생	
randn(d0, d1,, dn)	표준 정규분포에 따른 N차원 난수 발생	
randint(low[, high, size])	low 이상 high 미만의 정수형 난수 발생	
random_sample([size])		
random([size])	0.0이사 1.0미마이 시스청 나스 바새	
ranf([size])	0.0이상 1.0미만의 실수형 난수 발생	
sample([size])		
choice(a[, size, replace, p])	주어진 1차원 배열을 기반으로 무작위 샘플 추출	
bytes(length)	바이트형 난수 발생	

Pandas Library 상관관계




최소제곱법(Least Squared Method)


- 회귀직선 $y = \beta_0 + \beta_1 x$ 를 데이터 $(x_1, y_1), ..., (x_n, y_n)$ 에 적합(fit)시키는 과정
 - 데이터들에 가장 근접한 직선을 찾는 과정

$$Q = \sum_{i=1}^{n} (y_i - (\beta_0 + \beta_1 x_i))^2$$


을 최소화하는 직선을 선택하는 것.




오차분산(Error Variance)




$$\sigma_1^2 > \sigma_2^2$$



Interpretation of the error variance σ^2








Interpretation of slope parameter β_1

양의 상관관계


```
import matplotlib.pyplot as plt
from matplotlib import font_manager, rc
import matplotlib
font_location = "c:/Windows/fonts/malgun.ttf"
font_name = font_manager.FontProperties(fname=font_location).get_name()

matplotlib.rc('font', family=font_name)
height = [100, 120, 130, 140, 150, 160, 170, 180, 190]
foot_size = [200, 205, 210, 220, 230, 250, 270, 280, 285]
plt.scatter(height, foot_size)
plt.xlabel('](Cm)')
plt.ylabel('발크기(mm)')
plt.show()
```




음의 상관관계

```
height = [100, 200, 300, 400, 500, 600, 700, 800, 900]
temperature = [18.0, 17.5, 17, 16.5, 15, 14.5, 13, 12, 11]
plt.scatter(height, temperature)
plt.xlabel('산의높이(m)')
plt.ylabel('온도(°)')
plt.show()
```



```
import numpy as np
random_x = np.random.randint(0, 100, 50) # 1~100 사이의 난수를 50개 생성
random_y = np.random.randint(0, 100, 50) # 1~100 사이의 난수를 50개 생성
plt.scatter(random_x, random_y)
plt.show()
```



0.0 ~ 0.2	상관 관계가 거의 없다
0.2 ~ 0.4	약한 상관 관계
0.4 ~ 0.6	상관 관계가 있다
0.6 ~ 0.8	강한 상관 관계
0.8 ~ 1.0	매우 강한 상관 관계

- m_x is the mean of X
- m_y is the mean of Y
- r is the correlation between X and Y(Pearson's r):

$$r = \frac{\sum xy}{\sqrt{\sum x^2 \sum y^2}}, \quad (x = X - m_x, y = Y - m_y)$$

서울시 입장객과 각국 입국수에 따른 상관분석 자료

```
import ison
    import math
    import numpy as np
    import matplotlib.pyplot as plt
    import matplotlib
    from matplotlib import font_manager, rc
    import pandas as pd
11
   #[CODE 1]
12
   def correlation(x, y):
       n = Ien(x)
14
15
       vals = range(n)
16
       x sum = 0.0
       v sum = 0.0
       x sum pow = 0.0
19
       y_sum_pow = 0.0
       mul xy sum = 0.0
21
22
        for i in vals:
24
           mul_xy_sum = mul_xy_sum + float(x[i]) * float(y[i])
25
           x sum = x sum + float(x[i])
           y_sum = y_sum + float(y[i])
26
27
           x_sum_pow = x_sum_pow + pow(float(x[i]), 2)
28
           y_sum_pow = y_sum_pow + pow(float(y[i]), 2)
29
30
        trv:
            r = ((n * mul_xy_sum) - (x_sum * y_sum)) / math.sqrt(((n*x_sum_pow) - pow(x_sum, 2)) * ((n*y_sum_pow) - pow(y_sum, 2)))
31
32
        except:
            r = 0.0
34
35
        return r
36
```

```
37 #/CODE 21
   def setScatterGraph(tour_table, visit_table, tourpoint):
       tour = tour table[tour table['resNm'] = tourpoint]
       merge_table = pd.merge(tour, visit_table, left_index=True, right_index=True)
       fig = plt.figure()
       fig.suptitle(tourpoint + '상관관계 분석')
       plt.subplot(1, 3, 1)
       plt.xlabel('중국인 입국수')
       plt.ylabel('외국인 입장객수')
       r = correlation(list(merge table['china']), list(merge table['ForNum']))
       plt.title('r = \{:.5f\}'.format(r))
       plt.scatter(list(merge_table['china']), list(merge_table['ForNum']), edgecolor='none', alpha=0.75, s=6, c='black')
       plt.subplot(1, 3, 2)
       plt.xlabel('일본인 입국수')
       plt.ylabel('외국인 입장객수')
       r = correlation(list(merge table['japan']), list(merge table['ForNum']))
       plt.title('r = \{:.5f\}'.format(r))
       plt.scatter(list(merge table['iapan']), list(merge table['ForNum']), edgecolor='none', alpha=0.75, s=6, c='black')
       plt.subplot(1, 3, 3)
       plt.xlabel('미국인 입국수')
       plt.ylabel('외국인 입장객수')
       r = correlation(list(merge table['usa']), list(merge table['ForNum']))
       plt.title('r = \{:.5f\}'.format(r))
       plt.scatter(list(merge_table['usa']), list(merge_table['ForNum']), edgecolor='none', alpha=0.75, s=6, c='black')
       plt.tight layout()
       # 이미지 저장
       #fia = matplotlib.pvplot.acf()
       #fig.set_size_inches(10, 7)
       #fig.savefig(tourpoint+'.png', dpi=300)
       plt.show()
```

39

40

41

42 43 44

45

46 47 48

49

50

51

52

53 54 55

56

57 58

59

60 61 62

63

64

65 66

67

68 69

70

71 72

73 74

75 76


77

```
81
 82
        font location = "c:/Windows/fonts/malgun.ttf"
        font name = font manager.FontProperties(fname=font location).get name()
 84
        matplotlib.rc('font', family=font name)
 85
 86
        tpFileName = '서울특별시_관광지입장정보_2011_2016.json'
 87
        jsonTP = json.loads(open(tpFileName, 'r', encoding='utf-8').read())
        tour_table = pd.DataFrame(jsonTP, columns=('yyyymm', 'resNm', 'ForNum')) # 필요한 데이터만 추출
 89
        tour table = tour table.set index('yyyymm')
 90
        '''['창덕궁', '운현궁', '경복궁', '창경궁', '종묘', '국립중앙박물관', '서울역사박물관', '덕수궁', '서울시립미술관 본관', '태릉·강릉·조선왕릉전시관', '서대문형무소역사관', '서대문자연사박물관',
 91
 92
         '트릭아이미술관', '헌릉·인릉', '선릉·정릉', '롯데월드']'''
 93
 94
 95
        resNm = tour table.resNm.unique()
 96
 97
        fv_CFileName = '중국(112)_해외방문객정보_2011_2016.json'
98
        isonFV = ison.loads(open(fv CFileName, 'r', encoding='utf-8'),read())
        china_table = pd.DataFrame(jsonFV, columns=('yyyymm', 'visit_cnt'))
99
        china table = china table.rename(columns={'visit cnt': 'china'})
100
101
        china table = china table.set index('yyyymm')
102
        fv JFileName = '일본(130) 해외방문객정보 2011 2016.json'
103
        isonFY = ison.loads(open(fv JFileName, 'r', encoding='utf-8').read())
104
105
         japan table = pd.DataFrame(jsonFV, columns=('vyvymm', 'visit cnt'))
        japan_table = japan_table.rename(columns={'visit_cnt': 'japan'})
106
         iapan table = iapan table.set index('yyyymm')
107
108
        fv_UFileName = '미국(275)_해외방문객정보_2011_2016.json'
109
110
        jsonFY = json.loads(open(fv_UFileName, 'r', encoding='utf-8').read())
        usa_table = pd.DataFrame(jsonFV, columns=('yyyymm', 'visit cnt'))
111
        usa table = usa table.rename(columns={"visit cnt": "usa"})
112
        usa table = usa table.set index('yyyymm')
113
114
115
        fy table = pd.merge(china table, japan table, left index=True, right index=True)
116
        fy table = pd.merge(fy table, usa table, left index=True, right index=True)
117
        for tourpoint in resNm:
118
119
            setScatterGraph(tour table, fy table, tourpoint)
120
    if __name__ = "__main__":
121
122
        main()
```

79

80 | **def** main():

서울시 입장객과 각국 입국수에 따른 상관분석 자료



트릭아이미술관 0.340085 -0.150360 0.180945 헌릉・인릉 -0.581325 0.464530 -0.185389 선릉·정릉 -0.571526 0.388067 -0.124945 롯데월드 0.510559 0.235118 -0.126739

상관계수 분석

```
import ison
    import math
    import numpy as np
    import matplotlib.pyplot as plt
    import matplotlib
   from matplotlib import font manager, ro
    import pandas as pd
9
   '''[['창덕궁', -0.058791104060063125, 0.27744435701410114, 0.40281606330501574], ['운현궁', 0.44594488384450376, 0.3026152182879861,
   |0.2812576500158649], ['경복궁', 0.5256734293511214, -0.4352281861341233, 0.42513726387044926], ['창경궁', 0.4512325398089607,
. 12 │-0.16458589402253013, 0.6245403780269381], ['종묘', -0.5834218986767474, 0.5298702802205213, -0.12112666829294959], ['국립중앙박물관'
   │, 0.39663594900292837, -0.06923889417914424, 0.3789788348060077], ['서울역사박물관', 0.4169985898874495, 0.4929777868070643,
14 | 0.2411976107709704], ['덕수궁', 0.4332132943587757, -0.4326719125679966, 0.4808588469548069], ['서울시립미술관 본관', 0.0, 0.0, 0.0],
15 │['태릉 ㆍ 강릉 ㆍ 조선왕릉전시관', -0.08179909096513825, 0.0634032985209752, -0.068840[
                                                                                                                 china
                                                                                                                         japan
                                                                                                                                   usa
16 | 0.47262271531670347, 0.006098570233700235, 0.22900879409607508], ['서대문자연사박물관',
17 0.340084882575556, -0.15036015533747007, 0.18094502388483083], ['현롱・인롱', -0.581325
                                                                                                      tourpoint
18 -0.1853887818740637], ['선릉·정릉', -0.5715258789199192, 0.38806730592260075, -0.12494
                                                                                                        창덕궁 -0.058791 0.277444 0.402816
19 0.23511773800458452, -0.12673869767365747]]'''
                                                                                                        유현궁 0.445945 0.302615 0.281258
  f = open("rlist.txt", "r")
21
                                                                                                        경복궁 0.525673 -0.435228 0.425137
22 | r_table = f
                                                                                                        창경궁 0.451233 -0.164586 0.624540
23 | f.close()
24
                                                                                                          종묘 -0.583422 0.529870 -0.121127
                                                                                                  국립중앙박물관 0.396636 -0.069239
                                                                                                                              0.378979
   r table = pd.DataFrame(r list, columns=('tourpoint', 'china', 'japan', 'usa'))
27 | r table = r table.set index('tourpoint')
                                                                                                  서울역사박물관 0.416999 0.492978
                                                                                                                              0.241198
28 | r table
                                                                                                        덕수궁 0.433213 -0.432672 0.480859
                                                                                              서울시립미술관 본관 0.000000 0.000000 0.000000
                                                                                         태릉·강릉·조선왕릉전시관 -0.081799 0.063403 -0.068840
                                                                                               서대문형무소역사관 0.472623 0.006099 0.229009
                                                                                               서대문자연사박물관 0.000000 0.000000 0.000000
```

상관계수 분석

```
1 # 상관관계값이 없는 경우에는 삭제
2 r_table.drop('서울시립미술관 본관')
3 r_table.drop('서대문자연사박물관')
4 r_table = r_table.sort_values('china', ascending=False)
5 r_table.head() # default 가 5개
```

	china	japan	usa
tourpoint			
경복궁	0.525673	-0.435228	0.425137
롯데월드	0.510559	0.235118	-0.126739
서대문형무소역사관	0.472623	0.006099	0.229009
창경궁	0.451233	-0.164586	0.624540
운현궁	0.445945	0.302615	0.281258

```
# 중국인 입국수 대비 관광객 입장객수의 상관계수가 높은 순서대로 3개국의 비교
font_location = "c:/Windows/fonts/malgun.ttf"
font_name = font_manager.FontProperties(fname=font_location).get_name()
matplotlib.rc('font', family=font_name)
r_table.plot(kind='bar', rot=70)

plt.show()
```

